Detección y predicción de rellenos sanitarios en México mediante visión artificial: comparación de arquitecturas y modelos de fundación

Landfill Detection and Prediction in Mexico Using Computer Vision: A Comparison of Architectures and Foundation Models

Emilio REEMPLAZAR-apellidos[1*] y REEMPLAZAR: coautor o asesor (borrar si no aplica)[1]

[1] REEMPLAZAR: Departamento o carrera, Instituto Tecnológico de Querétaro, Querétaro, México

Correspondencia: Emilio REEMPLAZAR-apellidos (REEMPLAZAR-correo@dominio.mx)

Resumen. «REEMPLAZAR: Contexto y problema en 1–2 frases: por qué importa inventariar rellenos sanitarios en México.» «REEMPLAZAR: Método: qué modelos y qué datos se compararon.» «REEMPLAZAR: Resultados clave con cifras: «la configuración X alcanzó IoU = 0.xx frente a 0.yy de la línea base».» «REEMPLAZAR: Conclusión e implicación práctica. Objetivo total: 150–250 palabras.»

Palabras clave: rellenos sanitarios; visión artificial; segmentación semántica; percepción remota; modelos de fundación; DINOv3; AlphaEarth.

Abstract. «REEMPLAZAR: English abstract: same four moves (context, method, key results with numbers, conclusion).»

Keywords: landfills; computer vision; semantic segmentation; remote sensing; foundation models; DINOv3; AlphaEarth.

1 INTRODUCCIÓN

> ***Guía de redacción.*** *Estructura en embudo, 4 a 6 párrafos (0.75–1.25 páginas): (1) contexto amplio, (2) problema concreto, (3) estado del arte y brecha, (4) propuesta y contribuciones, (5) organización del documento. Toda afirmación factual necesita cifra y cita. Escribir esta sección casi al final.*

«REEMPLAZAR: Contexto: gestión de residuos sólidos en México y su impacto ambiental (lixiviados, emisiones de metano, contaminación de acuíferos). Incluir una o dos cifras oficiales con su cita.»

«REEMPLAZAR: Problema: los inventarios de sitios de disposición final están incompletos o desactualizados y existen sitios no regulados. Explicar por qué el monitoreo en campo no escala a nivel nacional.»

«REEMPLAZAR: Oportunidad: imágenes satelitales y segmentación semántica permiten un monitoreo a gran escala. Brecha: trabajos previos (citar) no cubren México, no comparan modelos de fundación o asumen grandes volúmenes de datos etiquetados.»

En este trabajo se aborda la detección de rellenos sanitarios en imágenes satelitales de México como un problema de segmentación semántica binaria, en un régimen de pocos datos etiquetados (menos de 100 imágenes con máscaras). Las contribuciones son las siguientes:

1. Se compara de forma controlada un conjunto de 5 configuraciones de segmentación (Tabla 2), que combinan codificadores preentrenados y arquitecturas U-Net, bajo el mismo conjunto de datos, particiones y protocolo de evaluación.
2. Se evalúa el aporte de las representaciones de modelos de fundación para observación de la Tierra (DINOv3 y AlphaEarth) frente a una línea base entrenada sin preentrenamiento.
3. «REEMPLAZAR: Contribución adicional: conjunto de datos etiquetado, código abierto, mapa de predicción nacional, etc. Borrar si no aplica.»

El resto del documento se organiza como sigue. La Sección 2 revisa el trabajo relacionado; la Sección 3 describe los datos; la Sección 4 detalla la metodología; la Sección 5 presenta los resultados, que se interpretan en la Sección 6; y la Sección 7 resume las conclusiones y el trabajo futuro.

2 TRABAJO RELACIONADO

> ***Guía de redacción.*** *Objetivo: ubicar tu trabajo en la literatura y justificar la brecha que cubres. Apunta a 15–25 referencias revisadas por pares. Termina cada subsección con una frase que conecte con tu propuesta. Agrega cada fuente a references.bib y cítala con* `@clave`*.*

2.1 Detección de rellenos sanitarios y residuos por percepción remota

«REEMPLAZAR: Revisión de la literatura: detección de vertederos y rellenos sanitarios con imágenes satelitales

o aéreas, índices espectrales, métodos clásicos y redes convolucionales. Citar al menos 4–6 trabajos.»

2.2 Segmentación semántica en imágenes satelitales

La arquitectura U-Net [1], concebida originalmente para segmentación de imágenes biomédicas, se ha convertido en una referencia para segmentación densa gracias a sus conexiones de salto entre codificador y decodificador. Es habitual sustituir su codificador por redes preentrenadas como las redes residuales [2] o transformers de visión [3]. «REEMPLAZAR: Agregar aplicaciones de U-Net y variantes en percepción remota, con cita.»

2.3 Modelos de fundación para observación de la Tierra

DINOv3 [4] es una familia de modelos visuales entrenados mediante aprendizaje autosupervisado, de la cual existe una variante preentrenada con imágenes satelitales. AlphaEarth Foundations [5] genera representaciones (embeddings) de la superficie terrestre a partir de múltiples fuentes de observación. «REEMPLAZAR: Verificar y completar la descripción técnica de ambos modelos (datos de preentrenamiento, resolución, dimensión del embedding) contra los artículos originales.»

2.4 Brecha de investigación

«REEMPLAZAR: Una frase que resuma lo que falta en la literatura y que este trabajo cubre: comparación sistemática de modelos de fundación para detección de rellenos sanitarios en México con pocos datos etiquetados.»

3 DATOS

> ***Guía de redacción.*** *Esta sección debe permitir que otra persona reconstruya tu conjunto de datos. Reporta fuentes, resolución, fechas, criterio de etiquetado, tamaños exactos y particiones. Si no cabe, mueve detalles al apéndice.*

3.1 Área de estudio y fuentes de imágenes

«REEMPLAZAR: Cobertura geográfica (estados o regiones), fuente de las imágenes (proveedor, sensor), resolución espacial, fechas de captura y tamaño de parche en píxeles.»

3.2 Etiquetado

El conjunto etiquetado consta de menos de 100 imágenes con máscaras binarias (relleno sanitario y fondo). «REEMPLAZAR: Cifra exacta de imágenes, proporción de píxeles positivos, criterio de etiquetado, herramienta utilizada, quién etiquetó y si hubo revisión cruzada.»

«REEMPLAZAR: Mapa de México con la ubicación de las muestras etiquetadas»

Figura 1. Distribución geográfica de las muestras. «REEMPLAZAR: Describir qué muestran los marcadores.»

3.3 Representaciones de entrada

Se consideran dos tipos de entrada:

- **Embeddings de 3 dimensiones (RGB).** «REEMPLAZAR: Cómo se obtienen y cómo se alinean con las máscaras.»
- **Embeddings de 64 dimensiones de AlphaEarth.** «REEMPLAZAR: Año(s) del embedding, resolución, remuestreo y alineación con las máscaras.»

3.4 Particiones y aumento de datos

«REEMPLAZAR: Estrategia de particiones entrenamiento, validación y prueba. Dado el tamaño reducido del conjunto, describir la validación cruzada y cómo se evita la fuga espacial (parches vecinos en particiones distintas). Aumentos aplicados.»

4 METODOLOGÍA

> ***Guía de redacción.*** *Describe todo lo necesario para reproducir los experimentos y justifica cada decisión de diseño (por ejemplo, por qué se congelan los codificadores). Las tablas se generan desde data/modelos.csv: edita ese archivo, no el texto.*

4.1 Arquitecturas evaluadas

Se evalúan 5 configuraciones (Tabla 2). El modelo M3, una U-Net estándar entrenada sin preentrenamiento, actúa como línea base. «REEMPLAZAR: Verificar que data/modelos.csv refleje exactamente las pruebas del

Tabla 1. Composición de las particiones del conjunto de datos.

Partición	Imágenes	Píxeles positivos (%)
Entrenamiento	«REEMPLAZAR: N»	«REEMPLAZAR: %»
Validación	«REEMPLAZAR: N»	«REEMPLAZAR: %»
Prueba	«REEMPLAZAR: N»	«REEMPLAZAR: %»

Tabla 2. Configuraciones de segmentación evaluadas.

ID	Codificador	Decodificador	Entrada	Congelado
M1	DINOv3 ViT-L/16 SAT	U-Net	RGB (3 dim)	Sí
M2	DINOv3	REEMPLAZAR: decodificador	RGB (3 dim)	Sí
M3	— (sin preentrenamiento)	U-Net (línea base)	RGB (3 dim)	No
M4	ResNet	REEMPLAZAR: decodificador	AlphaEarth (REEMPLAZAR: 3 o 64 dim)	Sí
M5	— (sin preentrenamiento)	U-Net	AlphaEarth (64 dim)	No

repositorio y agregar la justificación de cada configuración.»

4.2 Estrategia de entrenamiento

Los codificadores preentrenados (DINOv3 y ResNet) se mantienen congelados para preservar el conocimiento adquirido en el preentrenamiento y reducir el riesgo de sobreajuste con un conjunto etiquetado pequeño; solo se entrenan los módulos nuevos. «REEMPLAZAR: Función de pérdida y su justificación, optimizador, tasa de aprendizaje, programación, número de épocas, tamaño de lote, criterio de parada.»

4.3 Métricas de evaluación

Sean P la máscara predicha y G la máscara de referencia. Se reportan la intersección sobre unión (IoU), el coeficiente de Dice, la precisión y la exhaustividad (*recall*):

$$\text{IoU} = \frac{|P \cap G|}{|P \cup G|} \tag{1}$$

$$\text{Dice} = \frac{2\,|P \cap G|}{|P| + |G|} \tag{2}$$

$$\text{Precisión} = \frac{\text{TP}}{\text{TP} + \text{FP}}, \quad \text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \tag{3}$$

donde TP, FP y FN son los píxeles verdaderos positivos, falsos positivos y falsos negativos, respectivamente. «REEMPLAZAR: Indicar la métrica principal para comparar modelos y por qué (la IoU es habitual cuando la clase positiva es minoritaria).»

Tabla 3. Hiperparámetros comunes a todas las configuraciones.

Parámetro	Valor
Optimizador	«REEMPLAZAR: valor»
Tasa de aprendizaje	«REEMPLAZAR: valor»
Épocas	«REEMPLAZAR: valor»
Tamaño de lote	«REEMPLAZAR: valor»
Función de pérdida	«REEMPLAZAR: valor»
Tamaño de entrada	«REEMPLAZAR: valor»
Semillas aleatorias	«REEMPLAZAR: valor»
Hardware	«REEMPLAZAR: GPU y memoria»

4.4 Protocolo experimental

«REEMPLAZAR: Número de particiones y semillas, cómo se calcula la media y la desviación estándar, y qué garantiza una comparación justa (mismos datos, mismas particiones, mismo presupuesto de entrenamiento para todos los modelos).»

4.5 Reproducibilidad

«REEMPLAZAR: Versiones de software (Python, PyTorch, bibliotecas de segmentación), semillas, hardware y enlace al repositorio con código y configuraciones.»

5 RESULTADOS

> ***Guía de redacción.*** *Solo hechos: cifras, tablas y figuras, sin interpretar (eso va en la discusión). Cada tabla y figura debe entenderse sola gracias a su pie. La tabla de resultados se genera desde data/resultados.csv; las frases con cifras se calculan solas desde ese mismo archivo.*

5.1 Comparación cuantitativa

La Tabla 4 resume el desempeño de las 5 configuraciones en el conjunto de prueba. La mayor IoU corresponde a M1 (0.900), el mayor coeficiente de Dice a M1 (0.900), la mayor precisión a M1 (0.900) y la mayor exhaustividad a M2 (0.900). «REEMPLAZAR: Mencionar la magnitud de la diferencia frente a la línea base y si es mayor que la desviación estándar entre particiones.»

5.2 Resultados cualitativos

«REEMPLAZAR: Describir la Figura 2: qué se observa en aciertos y en fallos. Incluir al menos un caso donde los modelos fallen.»

5.3 Estudio de ablación

«REEMPLAZAR: Efecto de cada decisión de diseño: codificador congelado frente a ajustado, entrada de 3 frente a 64 dimensiones, tamaño del conjunto de entrenamiento. Presentar con una tabla o figura adicional.»

6 DISCUSIÓN

> ***Guía de redacción.*** *Aquí sí se interpreta. Responde en orden: ¿qué configuración rinde mejor y por qué?, ¿qué aporta cada*

BORRADOR

Tabla 4. Desempeño en el conjunto de prueba (media ± desviación estándar). En negrita, el mejor valor por métrica. **DATOS DE EJEMPLO: reemplazar data/resultados.csv y poner datos-ejemplo = false en data/estado.toml.**

Modelo	IoU ↑	Dice ↑	Precisión ↑	Recall ↑
M1	**0.900 ± 0.010**	**0.900 ± 0.010**	**0.900 ± 0.010**	0.800 ± 0.010
M2	0.800 ± 0.020	0.800 ± 0.020	0.800 ± 0.020	**0.900 ± 0.020**
M3	0.700 ± 0.030	0.700 ± 0.030	0.700 ± 0.030	0.700 ± 0.030
M4	0.600 ± 0.040	0.600 ± 0.040	0.600 ± 0.040	0.600 ± 0.040
M5	0.500 ± 0.050	0.500 ± 0.050	0.500 ± 0.050	0.500 ± 0.050

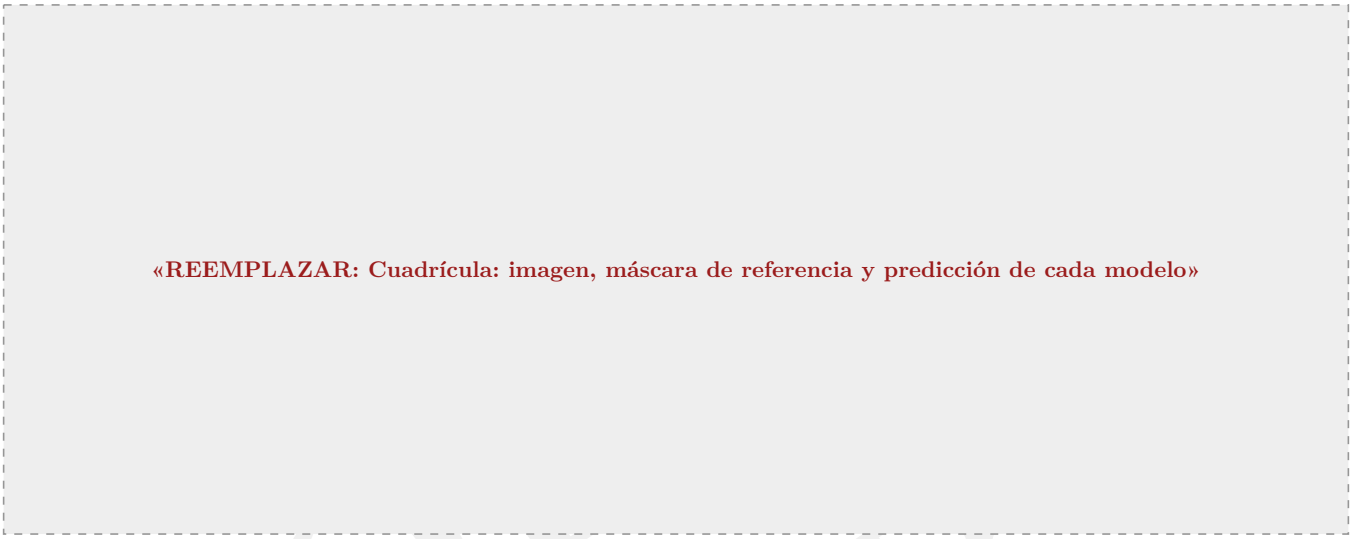


Figura 2. Ejemplos cualitativos de segmentación. «REEMPLAZAR: Indicar el orden de columnas y qué casos se muestran.»

> *componente?, ¿dónde falla el modelo?, ¿qué límites tienen las conclusiones? Evita afirmar más de lo que respaldan los datos (con menos de 100 imágenes, sé prudente).*

6.1 Interpretación de los resultados

«REEMPLAZAR: Explicar por qué una configuración supera a otras, apoyándote en la Tabla 4 y en la ablación. Relacionar con la literatura de la Sección 2.»

6.2 Análisis de errores

«REEMPLAZAR: Tipos de falsos positivos y falsos negativos observados (por ejemplo, minas, canteras, zonas áridas, construcciones, sitios parcialmente cubiertos). Referir a la Figura 2.»

6.3 Limitaciones

«REEMPLAZAR: Tamaño reducido del conjunto etiquetado, sesgo geográfico de las muestras, ausencia de validación en campo, variación temporal de los sitios y sensibilidad a las particiones.»

6.4 Implicaciones prácticas

«REEMPLAZAR: Qué significan los resultados para quienes inventarían o monitorean rellenos sanitarios, y qué se necesitaría para una aplicación a escala nacional.»

7 CONCLUSIONES Y TRABAJO FUTURO

> ***Guía de redacción.*** *Responde lo prometido en la introducción, con cifras. No introduzcas información nueva. Trabajo futuro: 2–3 líneas concretas, no una lista de deseos.*

«REEMPLAZAR: Conclusión principal con cifras (qué configuración resultó mejor y por cuánto), seguida de una o dos conclusiones secundarias (por ejemplo, el efecto de los embeddings de AlphaEarth).»

Trabajo futuro. «REEMPLAZAR: Ampliar el conjunto etiquetado, aplicar el modelo a escala nacional, validar en campo con autoridades ambientales y evaluar el ajuste fino de los codificadores.»

> ***Guía de redacción.*** *Casi todas las revistas exigen estas declaraciones. Borra las que tu destino no pida.*

DISPONIBILIDAD DE CÓDIGO Y DATOS

«REEMPLAZAR: URL del repositorio (con la versión o etiqueta citada), licencia, y qué se publica y qué no (por ejemplo, las máscaras sí, las imágenes con licencia restringida no).»

CONTRIBUCIÓN DE LOS AUTORES

«REEMPLAZAR: Según la taxonomía CRediT: conceptualización, curaduría de datos, análisis formal, investigación, metodología, software, supervisión, redacción del borrador original, redacción y revisión. Indicar quién hizo cada una.»

FINANCIAMIENTO

«REEMPLAZAR: Fuente y número de proyecto, o «Este trabajo no recibió financiamiento externo».»

CONFLICTO DE INTERESES

«REEMPLAZAR: «Los autores declaran no tener conflicto de intereses» o descripción del conflicto.»

AGRADECIMIENTOS

«REEMPLAZAR: Asesor, institución, personas que apoyaron el etiquetado o el cómputo.»

A MATERIAL SUPLEMENTARIO

> ***Guía de redacción.*** *Opcional. Resultados detallados por partición, curvas de entrenamiento, tablas extensas. Quita* `09-apendice` *de la lista en main.typ si no lo necesitas.*

«REEMPLAZAR: Contenido suplementario (resultados por partición, curvas de entrenamiento, configuraciones completas).»

REFERENCIAS

[1] O. Ronneberger, P. Fischer, y T. Brox, "U-Net: Convolutional Networks for Biomedical Image Segmentation", en *Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, Springer, 2015, pp. 234–241.

[2] K. He, X. Zhang, S. Ren, y J. Sun, "Deep Residual Learning for Image Recognition", en *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.

[3] A. Dosovitskiy *et al.*, "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale", en *International Conference on Learning Representations (ICLR)*, 2021.

[4] O. Siméoni *et al.*, "DINOv3". [En línea]. Disponible en: https://arxiv.org/abs/2508.10104

[5] C. F. Brown *et al.*, "AlphaEarth Foundations: An Embedding Field Model for Accurate and Efficient Global Mapping from Sparse Label Data". [En línea]. Disponible en: https://arxiv.org/abs/2507.22291

BORRADOR